

结构混乱文档

【仅供测试 · 内容虚构】

本文件用于测试 RAG 系统的健壮性,内容由脚本随机生成,不代表任何实际业务流程。

建议在导入系统前对原文做规范化处理,例如拆分段落、补全标点、统一大小写等。

本段没有标题,读者难以快速定位主题,这也是结构混乱文档的常见问题。

测试重点:Chunking 策略应当能识别段落边界并合理切分。

重复声明:本文件仅用于内部测试,所有数据均为虚构,不构成任何业务承诺。

重复声明:本文件仅用于内部测试,所有数据均为虚构,不构成任何业务承诺。

重复声明:本文件仅用于内部测试,所有数据均为虚构,不构成任何业务承诺。

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat.

Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

无标点的连续中文片段本文件测试场景应该覆盖无标点纯文本,系统需要自行切分否则会出现单一大chunk导致检索失败

1. 一、章节(1)列表混用

2. 二、章节(2)列表混用

3. 三、章节(3)列表混用

4. 四、章节(4)列表混用

5. 五、章节(5)列表混用

中文与英文混排:本段包含example@example.com邮箱地址、HTTP://example.com链接、+86-138-0000-0000电话号码等敏感信息,系统应正确处理。

TAB 分隔的文本系统应该正确解析 不要因为 TAB 就切错

超长无段落标题示例标题A标题B标题C混在一起系统需要根据语义或标点拆开

Markdown 风格标题(应该是 Heading)

内容:虽然 PDF 不识别 Markdown 语法,但 RAG 系统应该靠排版/字体识别这是标题。

本页 PDF 字号 10.0 与正文一致,系统需要靠加粗识别层级。

****加粗强调****(在 PDF 中表现为加粗,但 RAG 系统通常靠 fontSize + bold 识别)。

数字清单: 1,000 1,000.00 1,000.0000 0.1 0.01 0.001 -100 +200 ± 0.5 100% 50‰

日期: 2026-08-18 2026/08/18 2026年8月18日 2026.08.18 Aug 18, 2026

金额: ¥ 1,000.00 \$100 € 50 £ 30 HK\$200 NT\$500

结束语:本文档结束于【仅供测试 · 内容虚构】。